



大模型定价与 20 人团队 月度 Token 用量评估

覆盖 GLM-5.1 / Claude Opus 4.6 / GPT-5.4
输出正式汇报口径、预算区间与落地建议

版本：2026-04-15

执行摘要

面向管理层的 4 个决定性结论

预算基线

6.18 亿

20 人团队月度 token 基线预算

主成本池

57%

代码开发 + Review loop 占总量

最低人民币口径

GLM-5.1

但长上下文会触发更高分档

国际主力建议

GPT-5.4

Opus 4.6 适合高价值升级任务

GLM-5.1 当前公开人民币单价最低，但输入长度 $<32K / \geq 32K$ 分档会直接影响成本。

GPT-5.4 的价格、缓存输入、超长上下文能力组合最均衡，适合作为国际通用主力模型。

Claude Opus 4.6 适合复杂架构推演、关键疑难问题定位和最终高价值 Review，不适合全员全程默认主力。

更合理的规划不是只比单价，而是按“主力模型 + 升级模型 + 成本控制策略”组合决策。

三家模型价格总览

先看公开 API 单价，再看缓存和长上下文门槛

结论： GLM-5.1 人民币口径最低； GPT-5.4 国际价格最均衡； Claude Opus 4.6 适合高价值升级而非全量承接。

模型	输入价格	缓存 / 命中	输出价格	备注
GLM-5.1	6 / 8 元 (<32K / >=32K)	1.3 / 2 元 命中价	24 / 28 元	缓存存储限时免费 有效期至 8 月 31 日
Claude Opus 4.6	\$5 / MTok	缓存命中最高节省 90%	\$25 / MTok	Batch 50% 折扣 1M beta 上下文更贵
GPT-5.4	\$2.50 / 1M	\$0.25 / 1M cached input	\$15.00 / 1M	>272K 后输入 2x 输出 1.5x

最低人民币成本

GLM-5.1

适合中文研发协作与成本敏感场景

最均衡国际主力

GPT-5.4

缓存输入清晰、上下文能力强

高质量升级

Opus 4.6

适合复杂任务，不适合全量默认

三家模型限制总览

真正影响可用性的不是单价，而是上下文、最大输出和并发

模型	上下文窗口	最大输出	速率 / 并发	备注
GLM-5.1	200K	128K	官方未公开固定 RPM/TPM 按权益与并发管理	Coding Plan 并发不可单独申请 调整
Claude Opus 4.6	200K 标准 1M beta	128K	Tier 1: 50 RPM 30,000 ITPM / 8,000 OTPM	高价值复杂任务更合适
GPT-5.4	1,048,576	128K	Tier 1: 500 RPM / 500K TPM Tier 4: 10K RPM / 4M TPM	公开规格最完整也最透明

长上下文能力最强： GPT-5.4 。


复杂推理升级通道： Claude Opus 4.6 。

团队规模化成本优势： GLM-5.1 ，但要控制 $\geq 32K$ 输入档占比。

注意： GLM-5.1 模型页示例代码出现 `max_tokens=65536` ，但官方模型概览页写明最大输出为 128K ，本汇报以概览页

20 人团队月度 Token 基线模型

预算区间的关键不是点值，而是基线与波动范围



保守

370.9M

AI 辅助问答 + 有限 Review

基线

618.2M

AI 深度接入开发与测试循环

激进

865.5M

高频 agentic coding + 长上下文 + 重度 Review

规划区间建议按 3.7 亿到 8.7 亿 tokens/月，而不是只预留一个静态点值。


基线场景可作为预算、限流和路由策略的默认经营口径。

如果团队开始大规模使用自动修复、长上下文代码代理，消耗会向激进场景快速靠拢。

假设：20 人、22 个工作日、需求 / 开发 / 测试三环节都深度使用大模型

分环节用量拆分

代码开发与 Review loop 是绝对主成本池



最大头

56.9%

代码开发 + Review 占比最高

管理重点

缓存复用

高频往返和重复读取决定账单

不要误判

不是需求阶段

需求分析不是主成本来源

基线月费测算

同一基线流量下，模型路由策略比单价对比更重要

GLM-5.1

5,102 元 ~ 6,252 元 / 月

取决于 <32K / >=32K 输入长度分档；混合负载下更接近 5.6K 元/月输入 cached input 价格；若频繁超过 272K 上下文，成本会继续上升

GPT-5.4

\$2,828 / 月

Claude Opus 4.6

\$4,863 ~ \$6,259 / 月

适合作为升级模型；全量默认使用会显著放大账单

如果目标是人民币成本最低，优先考虑 GLM-5.1，但要严控长输入分档。

如果目标是国际主力模型，GPT-5.4 的成本 / 能力组合最均衡。

如果目标是难题突破率，保留 Claude Opus 4.6 作为升级通道，而不是日常默认流量入口。

模型分工建议

用“主力模型 + 升级模型”替代“单一最好模型”



国内优先：GLM-5.1 适合中文研发协作与预算敏感场景。

国际优先：GPT-5.4 适合作为默认主力模型。

不建议：把 Claude Opus 4.6 承接所有普通补全、样板代码和测试脚手架。

推荐策略：主力模型承接 80% 流量，升级模型处理 20% 的高价值难题

成本控制抓手

先抓主成本池，再抓长上下文，再抓缓存复用

抓住主成本池

优先优化代码开发 + Review loop，而不是只盯需求分析。

控制长上下文

避免 GLM-5.1 大量落到 $\geq 32K$ 输入档，避免 GPT-5.4 高频触发 $> 272K$ 计费门槛。

强制上下文裁剪

只传相关文件片段、关键日志片段和最小可复现信息。

开启缓存复用

在 IDE / Agent 层优先复用上下文，减少重复读仓库和日志。

做模型分级

主力模型负责规模化吞吐，贵模型只承担升级任务。

控制顺序建议：开发 Review → 长上下文 → 缓存复用 → 路由分级

推荐落地路径

先试点，再放量，再按成本和质量做路由收敛



推荐组合：如果国内研发占主导，就先以 GLM-5.1 为试点主力；如果需要统一全球研发体验，就先以 GPT-5.4 为主力，再把 Claude Opus 4.6 接成升级通道。

风险与注意事项

选型失败通常不是模型太弱，而是口径、路由和上下文管理失控

价格波动

GLM-5.1 当前价格配置带有效期；后续可能调整。

长上下文失控

随着 agentic coding 深入，超长上下文比例会快速抬升。

缓存收益不稳定

团队工具链不同，缓存命中率可能与预期差异较大。

跨币种比较偏差

GLM 用人民币、OpenAI/Anthropic 用美元；采购决策需补充汇率和税费口径。

建议每月回顾一次：价格、上下文分布、缓存命中率、失败重试率

附录：来源与口径

PPT 数字全部来自现有调研文档的公开口径

来源：OpenAI 官方 API Pricing 与 GPT-5.4 模型页。

来源：Anthropic 官方 Claude Opus 4.6 页面、发布页与 rate limits 文档。

来源：智谱官方模型概览、速率限制文档，以及官方价格页前端静态资源提取。

用量模型假设：20 人、22 个工作日、三环节都深度使用大模型；不含 embedding、图像 / 音视频、税费和代理层加价。

本 PPT 为管理汇报口径，不等同于企业协议价、私有部署价或真实采购合同价。

如需采购决策版，可进一步补充：人民币 / 美元统一汇率口径、税费口径、模型 SLA、数据合规要求、企业协议折扣。