

大模型定价、限制与研发团队月度用量评估

围绕 GLM-5.1、Claude Opus、GPT-5 的选型与预算分析

The right side of the slide features three vertical bars in blue, green, and orange. Overlaid on these are three horizontal bars with labels: an orange bar with '定价' (Pricing), a red bar with '限制' (Limits), and a green bar with '用量' (Usage).

定价

限制

用量

一页看结论

预算关键不在需求分析，而在开发与 Review 的高频循环

关键结论 1


20 人团队基线月消耗约 94.60M tokens
默认预算建议先以基线场景作为编制口径

关键结论 2

同等用量下：GLM-5.1 最低，GPT-5 次之，Claude Opus 4.1 最高
全员默认高端模型会显著抬高月成本

关键结论 3


建议采用“低成本主力 + 高质量升级模型”组合
复杂架构分析、关键 PR 二审再升级到 Opus



说明：Claude-opus-4.6 / GPT-5.4 非公开官方命名，报告分别按 Claude Opus 4.1 / GPT-5 对比。

比较口径与边界说明

先统一命名与价格口径，避免平台别名与官方 SKU 混淆



边界与风险

官方信息抓取不稳定时，采用公开聚合平台页面做辅助参考
不同路由平台、账号等级、采购方式，实际账单可能不同

本页核心目的

防止后续讨论时把“平台别名”与“官方型号”混为一谈
确保后续预算测算按同一比较口径展开

主流模型价格与限制横向对比

重点比较输入 / 输出价格、上下文窗口与限制口径

对比型号	输入价格	输出价格	缓存价格	上下文窗口	最大输出	限制口径
GLM-5.1	\$0.95 / 1M	\$3.15 / 1M	Read \$0.475 / 1M	202,752	65,535	公开统一限流未明确抓取
Claude Opus 4.1	\$15 / 1M	\$75 / 1M	Write \$18.75 / 1M Read \$1.50 / 1M	200K	32K	tier-based
GPT-5	\$1.25 / 1M	\$10 / 1M	Cached input \$0.125 / 1M	400K	128K	tier-based

直观认知
Claude 最贵，GPT 次之，GLM
当前参考口径最低

注意事项
缓存价格不能直接等同于基础 input 单价

注释
GLM 价格为转售参考口径

Token 消耗的主要来源在哪里

研发场景不是一次性问答，而是天然形成多轮循环



为什么开发 / Review 最耗 token

交互轮次最多，且每轮都会重复携带上下文
代码、日志、diff 与修改结果叠加放大输入 token

管理提示

如果要控预算，优先优化 Review loop 与上下文复用策略
需求生成通常不是成本大头

20 人团队三档月用量评估


建议把“基线场景”作为预算编制默认口径

场景	月输入 tokens	月输出 tokens	月总 tokens
保守	47.96M	16.28M	64.24M
基线	70.40M	24.20M	94.60M
激进	127.60M	44.00M	171.60M

基线场景
94.60M tokens / 月

场景解释

保守：刚开始试点；激进：深度 AI-native ；基线：已进入日常研发流程





堆叠柱展示输入 / 输出拆分，便于后续直接映射不同模型的 input/output 计费单价。

基线场景下，成本主要消耗在哪些环节

基线总量 94.60M tokens，其中代码开发占比最高

环节	月输入	月输出	月总量
需求生成	11.88M	4.84M	16.72M
代码开发	38.72M	13.20M	51.92M
测试验证	19.80M	6.16M	25.96M



预算控制提示


若后续要控预算，优先优化开发与 Review 的调用策略，而不是先压缩需求分析环节

同样用量下，不同模型月成本差异明显

基线场景成本未计缓存命中、企业折扣、Batch 与转售差价

模型	基线月成本
GLM-5.1	\$143.11
Claude Opus 4.1	\$2,871.00
GPT-5	\$330.00

解读
Claude 更适合高价值、高难度任务，
不宜作为全员日常默认底座



最适合回答“如果全员默认都用高端模型，会贵多少”。

推荐采用“分层模型策略”

真正高性价比通常不是“最强单模型”，而是“主力模型 + 专家模型”组合

默认流量

推荐模型：GPT-5 或 GLM-5.1

适用：

- 日常开发
- 常规 Review
- 测试辅助

目标：

覆盖高频、标准化、成本敏感任务



升级流量

推荐模型：Claude Opus 4.1

适用：

- 复杂架构分析
- 高风险 PR 二次 review
- 疑难性能问题定位

目标：

在关键复杂任务上保留高质量能力

策略收益

既保留复杂任务质量，又避免日常全量流量落在高价模型上导致成本失控

预算、治理与落地建议

建议先试运行 1 个月，再用真实调用日志校准预算模型

1 以“基线场景 94.60M tokens/ 月”作为预算测算起点

2 默认启用缓存、上下文复用、模板化 prompt

3 对 Review loop 设置轮次阈值，避免无上限反复对话

4 将环境排障、测例编写优先落到低成本模型

5 对关键任务保留高端模型升级通道

一句话收尾：建议采用低成本主力模型承接日常流量，以高质量模型承接关键复杂任务，在保证效果的同时控制团队级成本。